

用于图像超分的深度展开网络

摘要

基于学习的单图像超分辨率 (SISR) 方法不断展现出优于传统的基于模型的方法的有效性和高效性,这在主要归功于端到端的训练。然而,与基于模型的方法可以在统一的 MAP 框架下处理具有不同的缩放因子、模糊核和噪声级别的 SISR 问题不同,基于学习的方法通常缺乏这种灵活性。为了解决这一问题,本文提出了一个端到端可训练的深度展开网络,平衡了基于学习的方法和基于模型的方法。具体来说,通过半二次分裂算法展开 MAP,可以由固定迭代次数交替求解数据子问题和先验子问题。我们使用神经模块解决这两个子问题,可以得到一个端到端可训练的迭代网络。因此,该网络继承了基于模型方法的灵活性,可以通过单一模型对不同缩放因子的模糊、有噪声的图像进行超分辨率处理,同时保留了基于学习方法的优点。大量实验证明了该深度展开网络在灵活性、有效性和通用性方面具有优越性。

关键字: 单图像超分 深度展开网络 半二次分裂算法

目录

一、任务介绍	3
1.1 问题背景与研究意义	3
1.2 相关工作	4
1.2.1 退化模型	4
1.2.2 灵活的超分辨率图像重建方法	5
1.2.3 基于深度展开的图像复原	5
二、符号说明	6
三、模型的建立和求解	6
3.1 模型建立	6
3.2 模型求解	7
四、实验	9
4.1 PSNR 结果	10
4.2 视觉结果	11
五、模型的分析	12
5.1 对 \mathcal{D} 和 \mathcal{P} 的分析	12
5.2 对 \mathcal{H} 的分析	13
5.3 泛化能力	14
5.4 真实图像超分	14
六、模型的评价	14
6.1 模型的优点	15
6.2 模型的缺点	15
参考文献	15
A 附录 代码	22

一、任务介绍

1.1 问题背景与研究意义

单图像超分辨率 (SISR) 是指从低分辨率 (LR) 图像中恢复出自然且清晰细节的高分辨率 (HR) 对应图像的过程。这是低层计算机视觉中的经典的不适定的“逆问题”之一，具有广泛的实际应用，如提高高清显示器上的图像视觉质量 [1, 2] 以及提升其他高级视觉任务的性能 [3]。

尽管经过了几十年的研究，SISR 仍然需要进一步研究以用于学术和工业目的 [4, 5]。其困难主要在于现有 SISR 方法的简单退化假设与真实图像的复杂退化之间的不一致 [6]。实际上，对于一个缩放因子 s ，SISR[7–9] 的经典退化模型假设 LR 图像 y 是 HR 图像 x 的模糊、降采样的和噪声版本。从数学上讲，它可以表示为

$$y = (x \otimes k) \downarrow_s + n, \quad (1)$$

其中， \otimes 表示将 x 与模糊核 k 进行二维卷积， \downarrow_s 表示标准的 s 折下采样，即保留每个独立的 $s \times s$ 块的左上角像素，舍弃其他像素， n 通常假定为具有标准差（或噪声级别） σ [10] 的“加性高斯白噪声” (AWGN)。Eq. (1) 具有明确的物理意义，通过为高分辨率图像设置适当的模糊核、缩放因子和噪声，我们可以近似各种低分辨率图像。特别的，Eq. (1) 已在基于模型的方法中得到广泛研究，即在 MAP 框架下解决数据项和先验项组合的问题。

虽然基于模型的方法通常具有算法上的可解释性，但它们通常缺乏标准的评估标准，因为除了缩放因子 Eq. (1) 还涉及模糊核和添加的噪声。为方便起见，研究人员在没有考虑模糊核和噪声水平的情况下，使用双三次退化模型 [11–13]。然而，双三次退化模型在数学上是复杂的 [14]，这反过来阻碍了基于模型的方法的发展。出于这个原因，最近提出的 SISR 解决方案主要是基于学习的方法，学习一个从双三次下采样的 LR 到其 HR 估计的映射函数。事实上，基于学习的方法在改善双三次退化模型的 PSNR[15, 16] 和感知质量 [17–19] 方面取得了显著进展，其中基于 CNN 方法因为它们强大的学习能力和并行计算的速度最受欢迎。然而，利用 CNN 通过单一模型来处理 Eq. (1) 的工作却很少。与基于模型的方法不同，CNN 通常缺乏灵活性，无法通过单一端到端训练模型对不同缩放因子下的模糊、有噪声的 LR 图像进行超分辨率（见图 1）。

在本文中，我们提出了一种深度展开超分辨率网络 (USRNet) 来弥补基于学习的方法和基于模型的方法之间的差距。一方面，与基于模型的方法类似，USRNet 能够通过单一的模型有效的处理带有不同模糊核、缩放因子和噪声水平的经典退化模型。另一方面，和基于学习的方法相似，USRNet 可以端到端的训练，保证了有效性和效率。为了实现这一目标，我们首先通过半二次分裂算法展开基于模型的能量函数。相应地，我们可以得到一个推理过程，该过程迭代交替地求解两个子问题，一个与数据项相关，另

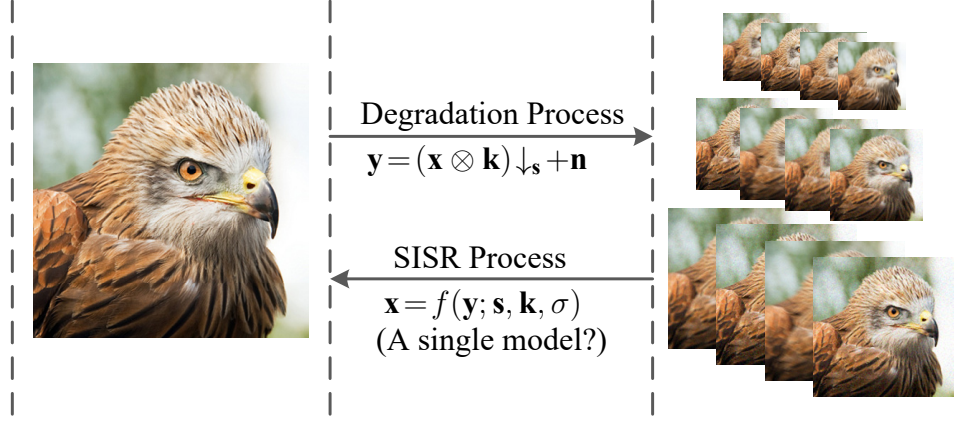


图 1 虽然单一退化模型 Eq. (1)可以为一张 HR 图像生成各种具有不同的模糊核、比例因子和噪声的 LR 图像，但是学习单一深度模型将所有此类 LR 图像还原为 HR 图像的研究仍然缺乏。

一个与先验项相关。然后，我们将该推理过程视为一个深度网络，通过用神经模块替换这两个子问题的解来实现。由于这两个子问题分别对应于强制降解一致性知识和保证去噪先验知识，USRNet 在明确的降解和先验约束下具有良好的理论基础，这是现有基于学习的单幅图像超分辨率（SISR）方法所不具备的独特优势。由于 USRNet 涉及为每个子问题设置超参数，因此网络中包含一个额外的超参数生成模块。此外，为了减少参数数量，所有的先验模块共享相同的架构和相同的参数。

这项工作的主要贡献如下：

- 1) 提出了一个端到端可训练的展开超分辨率网络（USRNet）。USRNet 首次尝试通过单个端到端训练模型处理具有不同缩放因子、模糊核和噪声水平的经典退化模型。
- 2) USRNet 融合了基于模型方法的灵活性和基于学习方法的优点，为弥补基于模型方法和基于学习方法之间的鸿沟提供了途径。
- 3) USRNet 本质上对解决方案施加了退化约束（即估计的 HR 图像应与退化过程一致）和先验约束（即估计的 HR 图像应具有自然特征）。
- 4) USRNet 在具有不同退化设置的 LR 图像上表现良好，显示了实际应用的巨大潜力。

1.2 相关工作

1.2.1 退化模型

退化模型的知识对于 SISR[6, 20] 的成功至关重要，因为它定义了如何从 HR 图像退化 LR 图像。除了经典退化模型和双三次退化模型外，在 SISR 文献中还提出了其他几种退化模型。

在一些早期的工作中，退化模型假设 LR 图像直接从 HR 图像上向下采样而不产生模糊，这与图像插值问题相对应 [21]。在 [22, 23] 中，进一步假设双三次下采样的图像被高斯噪声或 JPEG 压缩噪声所破坏。在 [1, 24] 中，退化模型主要关注高斯模糊并加上缩放因子为 3 的下采样。注意，与 Eq. (1) 不同，对于每个不同的 3×3 的 patch，他们的

下采样保持的是中心像素而不是左上角的像素。在 [25] 中，退化模型假设 LR 图片是模糊、双三次下采样的、带有一定高斯噪声的 HR 图片。通过假设上三次下采样的干净 HR 图片也是干净的，[26] 将退化模型视为去模糊的 LR 图像和双三次退化的 SISR 的组合。

虽然已经提出了许多退化模型，基于 CNN 用于经典退化模型的 SISR 关注较少，值得深入研究。

1.2.2 灵活的超分辨率图像重建方法

虽然基于 CNN 的 SISR 方法在处理双三次退化方面取得了巨大的成功，但将其应用于处理其他更实际的退化模型中并不直接。出于实用性考虑，最好设计一个灵活的超分辨率网络，能够考虑到三个关键因素：缩放因子、模糊核和噪声水平。

已经提出了几种通过单一模型解决具有不同尺度因子的双三次退化的方法，例如具有渐进式上采样的 LapSR[27]、具有尺度特定分支的 MDSR[28]、具有元上采样模块的 Meta-SR[29]。为了灵活地处理模糊的 LR 图像，在 [25, 30] 中提出的方法将 PCA 降维模糊核作为输入。然而，这些方法仅限于高斯模糊核。也许最灵活的基于 CNN 的工作是深度即插即用方法，它可以处理各种模糊核、尺度因子和噪声水平 [26, 31]。这类方法的主要思想是将学习到的 CNN 先验插入到 MAP 框架下的迭代解决方案中。不幸的是，这些方法本质上是基于模型的方法，计算负担很重，而且需要手动选择超参数。如何设计端到端可训练模型，以使用更少的迭代次数获得更好的结果，这仍未得到研究。

虽然基于学习的盲图像恢复最近受到了相当大的关注 [32–36]，但我们注意到这项工作主要关注非盲 SISR，假定 LR 图像、模糊核和噪声水平是已知的。事实上，非盲 SISR 仍是一个活跃的研究方向。首先，模糊核和噪声水平可以估计，或根据其他信息(如相机设置)知道。其次，用户可以通过调节模糊内核和噪声级别来控制锐度和平滑度的偏好。第三，非盲 SISR 是解决盲 SISR 的中间步骤。

1.2.3 基于深度展开的图像复原

除了深入的即插即用方法(参见, [5, 37–39])，深度展开方法也可以将基于模型的方法与基于学习的方法相结合。它们的主要区别是，后者通过在大型训练集上最小化损失函数，以端到端方式优化参数，从而通常在迭代次数较少的情况下产生更好的结果。早期的深度展开方法可以追溯到 [40–42]，其中提出了一种基于梯度下降算法的紧凑 MAP 推理方法用于图像去噪。自那以后，基于某些优化算法（例如半二次分裂 [43]，交替方向乘子法 [44] 和原始对偶法 [45, 46]）的众多深度展开方法被提出用于解决不同的图像恢复任务，如图像去噪 [47, 48]，图像去模糊 [49, 50]，图像压缩感知 [51, 52] 和图像去马赛克 [53]。

与基于纯学习的方法相比，深度展开方法具有可解释性，可以将退化约束融合到学习模型中。但是，它们中的大多数都存在以下一种或几种缺陷。(i) 在不使用深度 CNN

的情况下解决先验子问题，不足以实现良好的性能。(ii) 数据子问题没有闭式解，可能会阻碍收敛。(iii) 整个推理是通过分阶段和微调的方式进行训练的，而不是完整的端到端方式。此外，考虑到经典退化模型不存在深度展开 SISR 方法，提出克服上述问题的方法具有特别的意义。

二、符号说明

符号	说明
\otimes	二维卷积
\downarrow_s	标准 s 折下采样
\uparrow_s	标准的 s 折上采样
$\mathcal{F}(\cdot)$	快速傅立叶变换
$\mathcal{F}^{-1}(\cdot)$	逆快速傅立叶变换
$\overline{\mathcal{F}(\cdot)}$	$\mathcal{F}(\cdot)$ 的复共轭
\odot_s	对 $s \times s$ 的不同块进行元素乘法
\Downarrow_s	对 $s \times s$ 的不同块进行平均处理

三、模型的建立和求解

3.1 模型建立

双三次退化已经得到了很好的研究，因此探究他与传统退化模型的关系是有趣的。事实上，双三次退化模型可以通过在 Eq. (1) 中设置一个合适的模糊核来近似。为了实现这一点，我们采用数据驱动的方法，在一个较大规模的 HR/bicubic-LR 对 (x, y) 上最小化重构误差来解决下面的核估计问题。

$$\mathbf{k}_{bicubic}^{\times s} = \arg \min_{\mathbf{k}} \|(\mathbf{x} \otimes \mathbf{k}) \downarrow_s - \mathbf{y}\|. \quad (2)$$

图 2 显示了缩放系数为 2、3 和 4 的近似双三次内核。应该注意的是，由于下采样操作为每个不同的 $s \times s$ 的 patch 选择左上角的像素，缩放因子 2、3 和 4 的双立方内核分别向左上角方向移动 0.5、1 和 1.5 像素。

根据 MAP 框架，可以通过最小化下面的能量函数来估计 HR 图像

$$E(\mathbf{x}) = \frac{1}{2\sigma^2} \|\mathbf{y} - (\mathbf{x} \otimes \mathbf{k}) \downarrow_s\|^2 + \lambda \Phi(\mathbf{x}), \quad (3)$$

其中 $\frac{1}{2\sigma^2} \|\mathbf{y} - (\mathbf{x} \otimes \mathbf{k}) \downarrow_s\|^2$ 是数据项， $\Phi(\mathbf{x})$ 是先验项， λ 是平衡参数。




图 2 在经典 SISR 退化模型假设下，比例因子 2、3 和 4 的近似双三次核。请注意，这些核包含负值。

3.2 模型求解

为了得到 Eq. (3) 的展开推理，我们选择半二次分裂 (HQS) 算法，因为它在许多应用中具有简单性和快速收敛的特点。HQS 通过引入辅助变量 \mathbf{z} 来处理 Eq. (3)，从而得到以下近似等式：

$$E_\mu(\mathbf{x}, \mathbf{z}) = \frac{1}{2\sigma^2} \|\mathbf{y} - (\mathbf{z} \otimes \mathbf{k}) \downarrow_s\|^2 + \lambda \Phi(\mathbf{x}) + \frac{\mu}{2} \|\mathbf{z} - \mathbf{x}\|^2, \quad (4)$$

其中， μ 是惩罚项。这种问题可以通过迭代求解 \mathbf{x} 和 \mathbf{z} 的子问题来解决

$$\begin{cases} \mathbf{z}_k = \arg \min_{\mathbf{z}} \|\mathbf{y} - (\mathbf{z} \otimes \mathbf{k}) \downarrow_s\|^2 + \mu \sigma^2 \|\mathbf{z} - \mathbf{x}_{k-1}\|^2, \\ \mathbf{x}_k = \arg \min_{\mathbf{x}} \frac{\mu}{2} \|\mathbf{z}_k - \mathbf{x}\|^2 + \lambda \Phi(\mathbf{x}). \end{cases} \quad (5)$$

$$(6)$$

根据 Eq. (5)， μ 应该足够大，这样 \mathbf{x} 和 \mathbf{z} 大约在不动点。然而这会导致收敛变慢。因此，一个好的经验法则是迭代增加 μ 。为了方便起见，第 k 次迭代中的 μ 表示为 μ_k 。

可以看出数据项和先验项被解耦到 Eq. (5) 和 Eq. (6)，对于 Eq. (5) 的解，可以通过假设在圆形边界条件下进行卷积来利用快速傅里叶变换 (FFT)。值得注意的是，它有一个闭式解 [10]

$$\mathbf{z}_k = \mathcal{F}^{-1} \left(\frac{1}{\alpha_k} \left(\mathbf{d} - \overline{\mathcal{F}(\mathbf{k})} \odot_s \frac{(\mathcal{F}(\mathbf{k})\mathbf{d}) \downarrow_s}{(\overline{\mathcal{F}(\mathbf{k})}\mathcal{F}(\mathbf{k})) \downarrow_s + \alpha_k} \right) \right) \quad (7)$$

其中 \mathbf{d} 定义为：

$$\mathbf{d} = \overline{\mathcal{F}(\mathbf{k})}\mathcal{F}(\mathbf{y} \uparrow_s) + \alpha_k \mathcal{F}(\mathbf{x}_{k-1})$$

$\alpha_k \triangleq \mu_k \sigma^2$ 。特别值得注意的是，当 $s = 1$ 时，Eq. (7) 也适用于模糊的特殊情况。对于 Eq. (6) 的解，从贝叶斯的角度来看，它实际上对应于一个噪声等级为 $\beta_k \triangleq \sqrt{\lambda/\mu_k}$ 的去噪问题 [38]。

一旦确定展开优化，下一步就是设计展开超分辨率网络 (USRNet)。因为展开优化主要包括迭代求解一个数据子问题 Eq. (5) 和先验子问题 Eq. (6)，USRNet 应该在数据模型 \mathcal{D} 和先验模型 \mathcal{P} 中切换。此外，子问题的解也将超参数 α_k 和 β_k 作为输入，因此 USRNet 中还需要引入一个超参数模块 \mathcal{H} 。图 3 展示了带有 K 个迭代的 USRNet 的大体结构， K 被经验地设置为 8 以平衡速度和准确性。

数据模块 \mathcal{D} 数据模块起着 Eq. (7) 的作用，Eq. (7) 是数据子问题的闭合形式解。直观来说，它旨在找到一个更清晰的 HR 图像，该图像将数据项 $\|\mathbf{y} - (\mathbf{z} \otimes \mathbf{k})\downarrow_s\|^2$ 和二次正则化项 $\|\mathbf{z} - \mathbf{x}_{k-1}\|^2$ 与超参数 α_k 的加权组合最小化。由于数据项对应于退化模型，因此数据模块不仅具有将尺度因子 \mathbf{s} 和模糊内核 \mathbf{k} 作为输入的优势，而且还对解决方案施加了退化约束。实际上，很难手动设计这样一个简单但有用的多输入模块。为了简洁，Eq. (7) 改写为

$$\mathbf{z}_k = \mathcal{D}(\mathbf{x}_{k-1}, \mathbf{s}, \mathbf{k}, \mathbf{y}, \alpha_k). \quad (8)$$

注意到 \mathbf{x}_0 是通过最简单的最近邻插值用缩放因子 \mathbf{s} 插值 \mathbf{y} 来初始化的。值得注意的是，Eq. (8) 不包含可训练参数，数据项和上一个项之间无关，这带来了更好的泛化能力。为了实现，我们使用 PyTorch，FFT 和逆 FFT 运算可以分别由 `torch.rfft` 和 `torch.irfft` 实现。

先验模块 \mathcal{P} 先验模块旨在通过噪声级别为 β_k 的去噪器传入 \mathbf{z}_k 来获得更清晰的 HR 图像 \mathbf{x}_k 。受 [54] 的启发，我们提出了一个深度 CNN 去噪器，把噪声级别作为输入

$$\mathbf{x}_k = \mathcal{P}(\mathbf{z}_k, \beta_k). \quad (9)$$

该文献提出的去噪器名为 ResUNet，它将残差连接 [55] 集成到 U-Net[56] 中。U-Net 广泛应用于图像到图像的映射，而 ResNet 因其快速训练和通过多个残差块实现的大容量而广受欢迎。ResUNet 以连接的 \mathbf{z}_k 和噪声水平图作为输入，并输出去噪后的图像 \mathbf{x}_k 。通过这种方式，ResUNet 可以通过单一模型处理各种噪声水平，从而显著减少了总参数数量。按照 U-Net 的常见设置，ResUNet 涉及四个尺度，每个尺度都有一个在下采样和上采样操作之间的恒等跳跃连接。具体来说，从第一个尺度到第四个尺度，每一层的通道数量分别设置为 64、128、256 和 512。在下采样和上采样操作中，分别采用 2×2 步幅卷积 (SConv) 和 2×2 转置卷积 (TConv)。需要注意的是，在 SConv 和 TConv 层之后以及第一层和最后一层卷积层之后都没有激活函数。为了继承 ResNet 的优点，在每个尺度的下采样和上采样中都采用了 2 组残差块。根据 [28] 的建议，每个残差块由两个中间带有 ReLU 激活函数的 3×3 卷积层组成，并在输出端加上一个恒等跳跃连接。

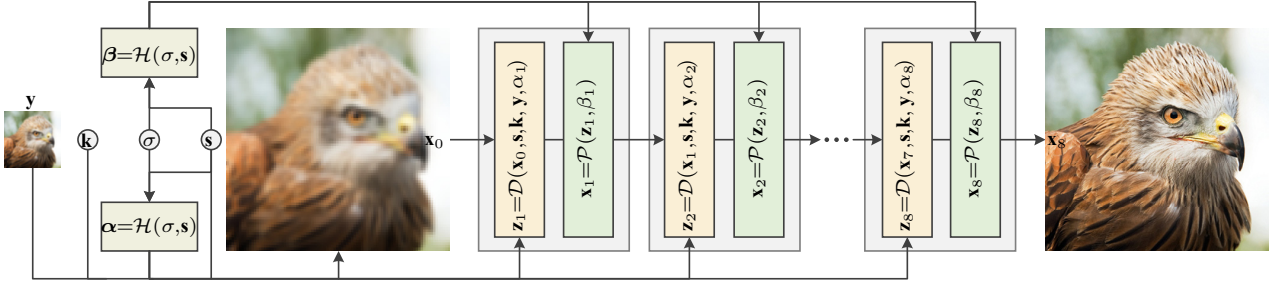


图 3 所提出的 USRNet 的整体架构，具有 $K = 8$ 次迭代。USRNet 将 LR 图像 y 、比例因子 s 、模糊核 k 和噪声水平 σ 作为输入，可以通过单个模型灵活地处理经典退化 Eq. (1)。具体来说，USRNet 由三个主要模块组成，包括使 HR 估计更清晰的数据模块 \mathcal{D} 、使 HR 估计更干净的先验模块 \mathcal{P} ，以及控制 \mathcal{D} 和 \mathcal{P} 输出的超参数模块 \mathcal{H}

超参数模块 \mathcal{H} 超参数模组充当“滑动条”控制 \mathcal{D} 和 \mathcal{P} 的输出。例如，随着 α_k 的增加，解 \mathbf{z}_k 将逐渐接近 \mathbf{x}_{k-1} 。根据 α_k 和 β_k 的定义， α_k 是由 σ 和 μ_k 决定的，而 β_k 则和 λ 和 μ_k 有关。尽管可以学习一个固定的 λ 和 μ_k ，我们认为如果 λ 和 μ_k 两个关键因素（即影响病态程度的缩放因子 s 和噪声级别 σ ）变化，则可以获得性能的提升。令 $\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_K]$ ， $\boldsymbol{\beta} = [\beta_1, \beta_2, \dots, \beta_K]$ ，我们使用一个单一模块来预测 $\boldsymbol{\alpha}$ 和 $\boldsymbol{\beta}$ ：

$$[\boldsymbol{\alpha}, \boldsymbol{\beta}] = \mathcal{H}(\sigma, \mathbf{s}). \quad (10)$$

超参数模块由三个全连接层组成，前两个激活函数为 ReLU，最后一个激活函数为 Softplus[57]。每层的隐藏节点数为 64。考虑到 α_k 和 β_k 应该为正值，并且 Eq. (7) 应该避免除以过小的 α_k ，Softplus 输出层后面额外加上了 $1e-6$ 。

四、实验

端到端训练旨在通过学习 USRNet 的可训练参数来在大量训练数据集上最小化损失函数。因此，本节主要描述训练数据、损失函数和训练设置。根据 [19]，我们使用 DIV2K[58] 和 Flickr2K[59] 作为 HR 训练数据集。LR 图像通过 Eq. (1) 合成。虽然 USRNet 主要关注 SISR，但它也适用于 $s = 1$ 的去模糊情况。因此，缩放因子是从 $\{1, 2, 3, 4\}$ 中选择的。然而，由于空间有限，本文不考虑去模糊实验。对于模糊内核，我们使用各向异性高斯内核，如 [1, 23, 25] 和运动模糊内核，如 [60]。我们将卷积核大小固定为 25×25 。对于噪音水平，我们将其范围设置为 $[0, 25]$ 。

关于损失函数，我们采用 L1 来评价 PSNR 性能。根据 [19]，一旦获得该模型，我们进一步采用 L1 损失、VGG 感知损失和相对对抗损失 [61]1: 1: 0.005 的加权组合，来感知质量权重。我们把这种微调的模型称为 USRGAN。像往常一样，USRGAN 只考虑缩放因子 4。我们不使用额外的损失来限制中间输出，因为上述损失效果很好。一个可能的原因是，先验模块在迭代过程中共享参数。

为了优化 USRNet 的参数，我们采用了 mini-batch 大小为 128 的 Adam 求解器 [62]。学习率从 1×10^{-4} 开始，每迭代 4×10^4 次减少 0.5 倍，最后以 3×10^{-6} 结束。值得指出的是，由于不同缩放因子的并行计算不可行，每个 mini-batch 只涉及一个随机比例因子。对于 USRGAN，其学习率固定为 1×10^{-5} 。USRNet 和 USRGAN 的 HR 图像的 patch size 设置为 96×96 。我们在亚马逊 AWS 云中的 4 个 Nvidia Tesla V100 GPU 上使用 PyTorch 训练模型。获得 USRNet 模型大约需要两天时间。













我们选择被广泛使用的彩色 BSD68 数据集 [63, 64] 来定量评估不同的方法。该数据集由 68 张具有微小结构和精细纹理的图像组成，因此在改进 PSNR 等定量指标方面具有挑战性。为了通过 Eq. (1) 合成相应的测试 LR 图像，应提供模糊内核和噪声水平。一般来说，使用大量模糊内核和噪音水平进行彻底评估是有帮助的，但是，这也会导致评估过程繁琐。因此，如表 1 所示，我们只考虑 12 个具有代表性和多样化的模糊内核，包括 4 个不同宽度的各向同性高斯内核（即 0.7、1.2、1.6 和 2.0），来自 [25] 的 4 个各向异性高斯内核和来自 [60, 65] 的 4 个运动模糊核。虽然有人指出，各向异性 Gaussian 内核足以完成 SISR 任务 [30, 66]，但可以处理更复杂的模糊内核的 SISR 方法将是实际应用中的首选。因此，有必要进一步分析不同方法的内核鲁棒性，因此我们将单独报告每个模糊内核而不是每种类型的模糊内核的 PSNR。虽然有人指出，模糊核应该随比例因子而变化 [5]，但我们认为 12 个模糊内核的多样性足以覆盖一个大的核空间。对于噪音水平，我们选择 2.55 (1%) 和 7.65 (3%)。

4.1 PSNR 结果

表 1 中报告了不同方法在不同退化设置下的平均 PSNR 结果。比较的方法包括 RCAN[16]、ZSSR [66]、IKC [67] 和 IRCNN [31]。具体而言，RCAN 是针对双三次插值退化的最先进的 PSNR 导向方法；ZSSR 是一种非盲零样本学习方法，能够处理各向异性高斯核的 Eq. (1)；IKC 是一种用于各向同性高斯核的盲迭代核校正方法；IRCNN 是一种基于非盲深度去噪器的即插即用方法。为了公平比较，我们通过将 IRCNN 的数据解替换为 Eq. (7) 来处理 Eq. (1)。请注意，根据 [9] 的方法，如果有必要，在计算 PSNR 之前，我们会修正像素偏移问题。

根据表 1，我们可以得出以下观察结果。首先，单一模型的 USRNet 在不同的放大倍数、模糊核和噪声水平上显著优于其他竞争方法。特别是，由于端到端训练，USRNet 在 30 次迭代中至少比 IRCNN 平均提高了 1dB 的 PSNR。其次，RCAN 在与双三次插值退化相似的退化设置下表现良好，但当退化偏离双三次插值时性能会严重下降。这种现象在 [6] 中有详细研究。第三，ZSSR 在小放大倍数下对各向同性和各向异性高斯模糊核表现良好，但在运动模糊核和大放大倍数下效果不佳。实际上，由于单图像学习策略，ZSSR 在处理严重退化的图像时难以捕捉自然图像特性。第四，IKC 在各向异性高斯核和运动模糊核上的泛化效果不好。

表 1 不同方法针对不同比例因子、模糊核和噪声水平组合的平均 PSNR(dB) 结果。最佳两个结果分别以 **red** 和 **blue** 颜色突出显示

Method	Scale Factor	Noise Level	Blur Kernel											
														
RCAN [16]	×2	0	29.48	26.76	25.31	24.37	24.38	24.10	24.25	23.63	20.31	20.45	20.57	22.04
	×3	0	24.93	27.30	25.79	24.61	24.57	24.38	24.55	23.74	20.15	20.25	20.39	21.68
	×4	0	22.68	25.31	25.59	24.63	24.37	24.23	24.43	23.74	20.06	20.05	20.33	21.47
ZSSR [66]	×2	0	29.44	29.48	28.57	27.42	27.15	26.81	27.09	26.25	14.22	14.22	16.02	19.39
	×3	0	25.13	25.80	25.94	25.77	25.61	25.23	25.68	25.41	16.37	15.95	17.35	20.45
	×4	0	23.50	24.33	24.56	24.65	24.52	24.20	24.56	24.55	16.94	16.43	18.01	20.68
IKC [67]	×4	0	22.69	25.26	25.63	25.21	24.71	24.20	24.39	24.77	20.05	20.03	20.35	21.58
IRCNN [31]	×2	0	29.60	30.16	29.50	28.37	28.07	27.95	28.21	27.19	28.58	26.79	29.02	28.96
	×3	0	25.97	26.89	27.07	27.01	26.83	26.76	26.88	26.67	26.22	25.59	26.14	26.05
	×3	2.55	25.70	26.13	25.72	25.33	25.28	25.18	25.34	24.97	25.00	24.64	24.90	24.73
	×3	7.65	24.58	24.68	24.59	24.39	24.24	24.20	24.27	24.02	23.94	23.77	23.75	23.69
	×4	0	23.99	25.01	25.32	25.45	25.36	25.26	25.34	25.47	24.69	24.39	24.44	24.57
USRNet	×2	0	30.55	30.96	30.56	29.49	29.13	29.12	29.28	28.28	30.90	30.65	30.60	30.75
	×3	0	27.16	27.76	27.90	27.88	27.71	27.68	27.74	27.57	27.69	27.50	27.50	27.41
	×3	2.55	26.99	27.40	27.23	26.78	26.55	26.60	26.72	26.14	26.90	26.80	26.69	26.49
	×3	7.65	26.45	26.52	26.10	25.57	25.46	25.40	25.49	25.00	25.39	25.47	25.20	25.01
	×4	0	25.30	25.96	26.18	26.29	26.20	26.15	26.17	26.30	25.91	25.57	25.76	25.70

虽然 USRNet 并不是为双三次插值退化设计的，但通过将图 2 中的近似双三次核作为输入来测试其结果是很有趣的。从表 8 可以看出，尽管没有在双三次核上进行训练，USRNet 仍然表现良好。

4.2 视觉结果

不同方法在放大 4 倍的无噪声低分辨率图像上超分辨率的视觉结果如图 4 所示。除了 RCAN、IKC 和 IRCNN 之外，我们还包括 RankSRGAN [68] 进行比较。请注意，由于 ZSSR 在放大 4 倍的情况下表现较差，因此省略了其视觉结果。从图 4 可以看出，USRNet 和 IRCNN 在具有运动模糊核的低分辨率图像上产生了比 RCAN 和 IKC 更好的视觉效果。虽然 USRNet 可以恢复比 IRCNN 更清晰的边缘，但两者都未能生成真实的纹理。如

PSNR(dB)	24.92/22.53/21.88	25.24/23.75/21.92	25.42/23.55/26.45	25.82/24.80/27.39	24.80/22.44/21.51	24.26/23.25/25.00
Zoomed LR ($\times 4$)	RCAN [16]	IKC [67]	IRCNN [31]	USRNet (ours)	RankSRGAN [68]	USRGAN (ours)

图 4 不同方法对比例因子为 4 的超分辨无噪声 LR 图像的视觉效果。模糊核显示在 LR 图像的右上角。请注意，RankSRGAN 和我们的 USRGAN 旨在实现感知质量，而不是 PSNR 值。

预期的那样，USRGAN 可以产生比 USRNet 视觉上更令人愉悦的结果。另一方面，如果退化严重偏离双三次退化，RankSRGAN 的表现不佳。相比之下，USRGAN 可以灵活处理各种低分辨率图像。

五、模型的分析

5.1 对 \mathcal{D} 和 \mathcal{P} 的分析

由于提出的 USRNet 是一种迭代方法，研究数据模块 \mathcal{D} 和先验模块 \mathcal{P} 在不同迭代中的高分辨率估计是很有意义的。图 5 显示了 USRNet 和 USRGAN 在不同迭代中对放大 4 倍的低分辨率图像的结果。正如所见， \mathcal{D} 和 \mathcal{P} 可以相互促进，进行迭代和交替的去模糊和细节恢复。有趣的是，由于特定任务训练， \mathcal{P} 还可以作为高频恢复的细节增强器。此外，它并不减少模糊核引起的退化，这验证了 \mathcal{D} 和 \mathcal{P} 之间的解耦。因此，端到端训练的 USRNet 在高斯去噪器基于即插即用单图像超分辨率 (SISR) 方面具有特定任务的优势。为了定量分析 \mathcal{D} 的作用，我们训练了一个 5 次迭代的 USRNet 模型，结果表明平均 PSNR 值在高斯模糊核上减少约 0.1dB，在运动模糊核上减少约 0.3dB。这进一步表明 \mathcal{D} 旨在消除模糊核引起的退化。此外，可以看到 USRGAN 在前几次迭代中与 USRNet 有相似的结果，但在最后几次迭代中会恢复微小的结构和细腻的纹理。




图 5 USRNet (上行) 和 USRGAN (下行) 不同迭代中的 HR 估计。初始 HR 估计 x_0 是 LR 图像的最近邻插值版本。缩放因子为 4, LR 图像的噪声水平为 2.55 (1%), 模糊核显示在 x_0 的右上角。

5.2 对 \mathcal{H} 的分析

图 6 显示了超参数模块在不同放大倍数 s 和噪声水平 σ 下的输出。从图 6(a) 可以观察到, α 与 σ 正相关, 并随 s 变化。这实际上与 3.2 中 α_k 的定义和分析一致。从图 6(b) 可以看到, β 随着迭代次数的增加而呈下降趋势, 并随着放大倍数和噪声水平的增加而增加。这意味着 HR 估计的噪声水平在迭代中逐渐减少, 复杂的退化需要较大的 β_k 来处理问题的病态性。值得指出的是, 学习到的超参数设置与 IRCNN [31] 的设置一致。总的来说, 学习到的 \mathcal{H} 是有意义的, 它发挥了正确的作用。

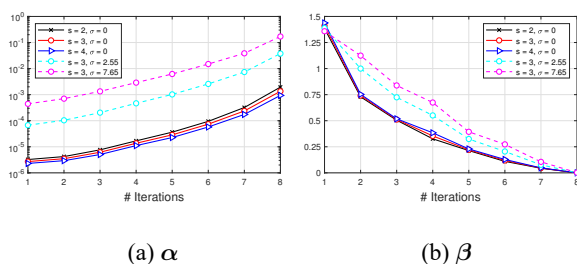


图 6 超参数模块 \mathcal{H} 的输出, 即 (a) α 和 (b) β , 相对于 s 和 σ 的不同组合。

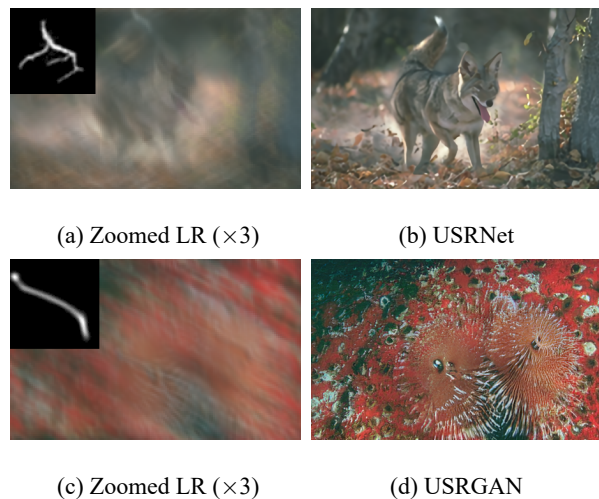


图 7 这张图展示了 USRNet 和 USRGAN 的泛化性。(a) 和 (c) 中的内核大小分别为 67×67 和 70×70 。这两个核选自 [69]。

5.3 泛化能力

如前所述，所提出的方法由于数据项和先验项的解耦而具有良好的泛化性。为了展示这一优势，图 7 显示了 USRNet 和 USRGAN 在核大小远大于训练大小 25×25 的低分辨率图像上的视觉结果。可以看出，USRNet 和 USRGAN 都能产生视觉上令人愉悦的结果，这归因于可训练的无参数数据模块。值得指出的是，USRGAN 是在放大 4 倍上训练的，而图 7 (b) 显示了其在放大 3 倍上的视觉结果。这进一步表明 USRGAN 的先验模块可以泛化到其他放大倍数。总的来说，所提出的深度展开架构在泛化性方面具有优势。

5.4 真实图像超分

由于 Eq. (7) 是基于圆形边界条件的假设，对于实际的低分辨率图像通常需要进行适当的边界处理。我们使用以下三个步骤进行这种预处理。首先，将低分辨率图像插值到所需大小。其次，采用 [70] 中提出的带有模糊核的插值图像的边界处理方法。最后，将下采样的边界填充到原始低分辨率图像。图 9 显示了 USRNet 在放大 4 倍的实际低分辨率图像上的视觉结果。模糊核是基于用户偏好手动选择的宽度为 2.2 的各向同性高斯核。从图 9 可以看出，所提出的 USRNet 可以重建具有更好视觉质量的高分辨率图像。

六、模型的评价

本文以经典的 SISIR 退化问题为研究对象，提出了一种深度展开的超分网络。受到基于模型的方法的展开优化启发，我们设计了一个端到端可训练的深度网络，该网络融合了基于模型方法的灵活性和基于学习方法的优点。该网络的新颖之处在于它可以通过一个单一的模型来处理经典的退化模型。具体来说，该网络由三个可解释模块组成，包括能够把 HR 估计的更清晰的数据模块，能把 HR 估计的更干净的先验模块，和控制其他两个模块输出的超参数模块。结果表明，该方法既能对结果进行退化约束，又能对结果进行先验约束。大量的实验证明了该方法的灵活性、有效性和通用性，用于超分各种退化的 LR 图像。我们相信，我们的工作可以使图像恢复研究社区受益。

Scale Factor	Set5	Set14	BSD100	Urban100
$\times 2$	37.72	33.49	32.10	31.79
$\times 3$	34.45	30.51	29.18	28.38
$\times 4$	32.45	28.83	27.69	26.44

图 8 USRNet 在常用测试数据集上的双三次退化平均 PSNR(dB) 结果.




图 9 USRNet ($\times 4$) 在真实 LR 图像上的视觉结果。

6.1 模型的优点

- \mathcal{D} 与 \mathcal{P} 解耦，有解释性和泛化性
- 可以实现单个网络对不同缩放倍数、噪声的图像进行超分，恢复图像质量高

6.2 模型的缺点

- 训练过程中展开层数需要手动设置，展开层数越高，训练显存开销越大

参考文献

- [1] PELEG T, ELAD M. A statistical prediction model based on sparse representations for single image super-resolution[J]. IEEE transactions on image processing, 2014, 23(6): 2569-2582.
- [2] SIU W C, HUNG K W. Review of image interpolation and super-resolution[C]//Proceedings of The 2012 Asia Pacific Signal and Information Processing Association Annual Summit and Conference. [S.l.]: IEEE, 2012: 1-10.
- [3] DAI D, WANG Y, CHEN Y, et al. Is image super-resolution helpful for other vision tasks? [C]//2016 IEEE Winter Conference on Applications of Computer Vision (WACV). [S.l.]: IEEE, 2016: 1-9.
- [4] LI Y, GU S, MAYER C, et al. Group sparsity: The hinge between filter pruning and decomposition for network compression[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. [S.l.: s.n.], 2020: 8018-8027.
- [5] ZHANG K, ZHOU X, ZHANG H, et al. Revisiting single image super-resolution under internet environment: blur kernels and reconstruction algorithms[C]//Advances in Multimedia Information Processing–PCM 2015: 16th Pacific-Rim Conference on Multimedia, Gwangju, South Korea, September 16-18, 2015, Proceedings, Part I 16. [S.l.]: Springer, 2015: 677-687.
- [6] EFRAT N, GLASNER D, APARTSIN A, et al. Accurate blur models vs. image priors in single image super-resolution[C]//Proceedings of the IEEE International Conference on Computer Vision. [S.l.: s.n.], 2013: 2832-2839.
- [7] ELAD M, FEUER A. Restoration of a single superresolution image from several blurred, noisy, and undersampled measured images[J]. IEEE transactions on image processing, 1997, 6(12):1646-1658.

- [8] FARSIU S, ROBINSON D, ELAD M, et al. Advances and challenges in super-resolution [J]. International Journal of Imaging Systems and Technology, 2004, 14(2):47-57.
- [9] LIU C, SUN D. On bayesian adaptive video super resolution[J]. IEEE transactions on pattern analysis and machine intelligence, 2013, 36(2):346-360.
- [10] ZHAO N, WEI Q, BASARAB A, et al. Fast single image super-resolution using a new analytical solution for l2-l2 problems[J]. IEEE Transactions on Image Processing, 2016, 25(8):3683-3697.
- [11] DONG C, LOY C C, HE K, et al. Image super-resolution using deep convolutional networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 38(2): 295-307.
- [12] TIMOFTE R, DE SMET V, VAN GOOL L. A+: Adjusted anchored neighborhood regression for fast super-resolution[C]//Computer Vision—ACCV 2014: 12th Asian Conference on Computer Vision, Singapore, Singapore, November 1-5, 2014, Revised Selected Papers, Part IV 12. [S.l.]: Springer, 2015: 111-126.
- [13] YANG J, WRIGHT J, HUANG T, et al. Image super-resolution as sparse representation of raw image patches[C]//2008 IEEE conference on computer vision and pattern recognition. [S.l.]: IEEE, 2008: 1-8.
- [14] KEYS R. Cubic convolution interpolation for digital image processing[J]. IEEE transactions on acoustics, speech, and signal processing, 1981, 29(6):1153-1160.
- [15] KIM J, LEE J K, LEE K M. Accurate image super-resolution using very deep convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2016: 1646-1654.
- [16] ZHANG Y, LI K, LI K, et al. Image super-resolution using very deep residual channel attention networks[C]//Proceedings of the European conference on computer vision (ECCV). [S.l.: s.n.], 2018: 286-301.
- [17] LEDIG C, THEIS L, HUSZÁR F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2017: 4681-4690.
- [18] SAJJADI M S, SCHOLKOPF B, HIRSCH M. Enhancenet: Single image super-resolution through automated texture synthesis[C]//Proceedings of the IEEE international conference on computer vision. [S.l.: s.n.], 2017: 4491-4500.

- [19] WANG X, YU K, WU S, et al. Esrgan: Enhanced super-resolution generative adversarial networks[C]//Proceedings of the European conference on computer vision (ECCV) workshops. [S.l.: s.n.], 2018: 0-0.
- [20] YANG C Y, MA C, YANG M H. Single-image super-resolution: A benchmark[C]//Computer Vision—ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part IV 13. [S.l.]: Springer, 2014: 372-386.
- [21] CASELLES V, MOREL J M, SBERT C. An axiomatic approach to image interpolation [J]. IEEE Transactions on image processing, 1998, 7(3):376-386.
- [22] LI T, HE X, QING L, et al. An iterative framework of cascaded deblocking and super-resolution for compressed images[J]. IEEE Transactions on Multimedia, 2017, 20(6): 1305-1320.
- [23] SINGH A, PORIKLI F, AHUJA N. Super-resolving noisy images[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2014: 2846-2853.
- [24] DONG W, ZHANG L, SHI G, et al. Nonlocally centralized sparse representation for image restoration[J]. IEEE transactions on Image Processing, 2012, 22(4):1620-1630.
- [25] ZHANG K, ZUO W, ZHANG L. Learning a single convolutional super-resolution network for multiple degradations[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2018: 3262-3271.
- [26] ZHANG K, ZUO W, ZHANG L. Deep plug-and-play super-resolution for arbitrary blur kernels[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. [S.l.: s.n.], 2019: 1671-1681.
- [27] LAI W S, HUANG J B, AHUJA N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2017: 624-632.
- [28] LIM B, SON S, KIM H, et al. Enhanced deep residual networks for single image super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. [S.l.: s.n.], 2017: 136-144.
- [29] HU X, MU H, ZHANG X, et al. Meta-sr: A magnification-arbitrary network for super-resolution[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. [S.l.: s.n.], 2019: 1575-1584.

- [30] RIEGLER G, SCHULTER S, RUTHER M, et al. Conditioned regression models for non-blind single image super-resolution[C]//Proceedings of the IEEE International Conference on Computer Vision. [S.l.: s.n.], 2015: 522-530.
- [31] ZHANG K, ZUO W, GU S, et al. Learning deep cnn denoiser prior for image restoration [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2017: 3929-3938.
- [32] CHEN Y, TAI Y, LIU X, et al. Fsrnet: End-to-end learning face super-resolution with facial priors[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2018: 2492-2501.
- [33] LUGMAYR A, DANELLJAN M, TIMOFTE R. Unsupervised learning for real-world super-resolution[C]//2019 IEEE/CVF International Conference on Computer Vision Workshop (ICCVW). [S.l.]: IEEE, 2019: 3408-3416.
- [34] REN D, ZHANG K, WANG Q, et al. Neural blind deconvolution using deep priors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. [S.l.: s.n.], 2020: 3341-3350.
- [35] SHEN Z, LAI W S, XU T, et al. Deep semantic face deblurring[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2018: 8260-8269.
- [36] YASARLA R, PERAZZI F, PATEL V M. Deblurring face images using uncertainty guided multi-stream semantic networks[J]. IEEE Transactions on Image Processing, 2020, 29: 6251-6263.
- [37] BRIFMAN A, ROMANO Y, ELAD M. Unified single-image and video super-resolution via denoising algorithms[J]. IEEE Transactions on Image Processing, 2019, 28(12):6063-6076.
- [38] CHAN S H, WANG X, ELGENDY O A. Plug-and-play admm for image restoration: Fixed-point convergence and applications[J]. IEEE Transactions on Computational Imaging, 2016, 3(1):84-98.
- [39] HEIDE F, DIAMOND S, NIESSNER M, et al. Proximal: Efficient image optimization using proximal algorithms[J]. ACM Transactions on Graphics (TOG), 2016, 35(4):1-15.
- [40] BARBU A. Training an active random field for real-time image denoising[J]. IEEE Transactions on Image Processing, 2009, 18(11):2451-2462.

- [41] SAMUEL K G, TAPPEN M F. Learning optimized map estimates in continuously-valued mrf models[C]//2009 IEEE Conference on Computer Vision and Pattern Recognition. [S.l.]: IEEE, 2009: 477-484.
- [42] SUN J, TAPPEN M F. Learning non-local range markov random field for image restoration [C]//CVPR 2011. [S.l.]: IEEE, 2011: 2745-2752.
- [43] AFONSO M V, BIOUCAS-DIAS J M, FIGUEIREDO M A. Fast image recovery using variable splitting and constrained optimization[J]. IEEE transactions on image processing, 2010, 19(9):2345-2356.
- [44] BOYD S, PARIKH N, CHU E, et al. Distributed optimization and statistical learning via the alternating direction method of multipliers[J]. Foundations and Trends® in Machine learning, 2011, 3(1):1-122.
- [45] ADLER J, ÖKTEM O. Learned primal-dual reconstruction[J]. IEEE transactions on medical imaging, 2018, 37(6):1322-1332.
- [46] CHAMBOLLE A, POCK T. A first-order primal-dual algorithm for convex problems with applications to imaging[J]. Journal of mathematical imaging and vision, 2011, 40: 120-145.
- [47] CHEN Y, POCK T. Trainable nonlinear reaction diffusion: A flexible framework for fast and effective image restoration[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6):1256-1272.
- [48] LEFKIMMIATIS S. Non-local color image denoising with convolutional neural networks [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2017: 3587-3596.
- [49] KRUSE J, ROTHER C, SCHMIDT U. Learning to push the limits of efficient fft-based image deconvolution[C]//Proceedings of the IEEE International Conference on Computer Vision. [S.l.: s.n.], 2017: 4586-4594.
- [50] SCHMIDT U, ROTH S. Shrinkage fields for effective image restoration[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2014: 2774-2781.
- [51] SUN J, LI H, XU Z, et al. Deep admm-net for compressive sensing mri[J]. Advances in neural information processing systems, 2016, 29.

- [52] ZHANG J, GHANEM B. Ista-net: Interpretable optimization-inspired deep network for image compressive sensing[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2018: 1828-1837.
- [53] KOKKINOS F, LEFKIMMIATIS S. Deep image demosaicking using a cascade of convolutional residual denoising networks[C]//Proceedings of the European conference on computer vision (ECCV). [S.l.: s.n.], 2018: 303-319.
- [54] ZHANG K, ZUO W, ZHANG L. Ffdnet: Toward a fast and flexible solution for cnn-based image denoising[J]. IEEE Transactions on Image Processing, 2018, 27(9):4608-4622.
- [55] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2016: 770-778.
- [56] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. [S.l.]: Springer, 2015: 234-241.
- [57] GLOROT X, BORDES A, BENGIO Y. Deep sparse rectifier neural networks[C]//Proceedings of the fourteenth international conference on artificial intelligence and statistics. [S.l.]: JMLR Workshop and Conference Proceedings, 2011: 315-323.
- [58] AGUSTSSON E, TIMOFTE R. Ntire 2017 challenge on single image super-resolution: Dataset and study[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. [S.l.: s.n.], 2017: 126-135.
- [59] TIMOFTE R, AGUSTSSON E, VAN GOOL L, et al. Ntire 2017 challenge on single image super-resolution: Methods and results[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. [S.l.: s.n.], 2017: 114-125.
- [60] BORACCHI G, FOI A. Modeling the performance of image restoration from motion blur [J]. IEEE Transactions on Image Processing, 2012, 21(8):3502-3517.
- [61] JOLICOEUR-MARTINEAU A. The relativistic discriminator: a key element missing from standard gan[J]. arXiv preprint arXiv:1807.00734, 2018.
- [62] KINGMA D P. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.

- [63] MARTIN D, FOWLKES C, TAL D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[C]//Proceedings eighth IEEE international conference on computer vision. ICCV 2001: volume 2. [S.l.]: IEEE, 2001: 416-423.
- [64] ROTH S, BLACK M J. Fields of experts[J]. International Journal of Computer Vision, 2009, 82:205-229.
- [65] LEVIN A, WEISS Y, DURAND F, et al. Understanding and evaluating blind deconvolution algorithms[C]//2009 IEEE conference on computer vision and pattern recognition. [S.l.]: IEEE, 2009: 1964-1971.
- [66] SHOCHER A, COHEN N, IRANI M. “zero-shot” super-resolution using deep internal learning[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2018: 3118-3126.
- [67] GU J, LU H, ZUO W, et al. Blind super-resolution with iterative kernel correction[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. [S.l.: s.n.], 2019: 1604-1613.
- [68] ZHANG W, LIU Y, DONG C, et al. Ranksrgan: Generative adversarial networks with ranker for image super-resolution[C]//Proceedings of the IEEE/CVF international conference on computer vision. [S.l.: s.n.], 2019: 3096-3105.
- [69] PAN J, SUN D, PFISTER H, et al. Blind image deblurring using dark channel prior[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2016: 1628-1636.
- [70] LIU R, JIA J. Reducing boundary artifacts in image deconvolution[C]//2008 15th IEEE International Conference on Image Processing. [S.l.]: IEEE, 2008: 505-508.
- [71] VENKATAKRISHNAN S V, BOUMAN C A, WOHLBERG B. Plug-and-play priors for model based reconstruction[C]//2013 IEEE global conference on signal and information processing. [S.l.]: IEEE, 2013: 945-948.

附录 A 代码

<https://github.com/ZhizhengFu/Implement-USRNet>